

CSE-CIC-IDS2018

Security AI

최종 실험 보고서

취업 포트폴리오 · 기술 검토용 | 저장소 실증 기반

데이터의 문제를 발견하고, 실험 설계를 다시 검증하다

대규모 보안 데이터의 중복·label conflict·split leakage 가능성·class prior distortion을 진단하고, feature-only split과 frequency-aware 학습으로 실험 설계를 재구성한 Security AI 프로젝트.

표 1. 핵심 결과와 평가 범위

탐지 품질 후보	LightGBM V4-B2 / Macro F1 0.808655
경량 추론 후보	DNN FP32 / 0.1286 MiB
양자화 후보	TorchAO INT8 / 0.0459 MiB
평가 범위	V4 Full Validation; CPU benchmark는 WSL2 x86
검토 기준일	2026-10-06 / 현재 저장소 직접 확인

Test V2는 V3 최종 평가에서 이미 사용되었다. V4의 모델 선택·추가 튜닝에는 재사용하지 않았으며, 독립 final holdout 검증은 남아 있다.

프로젝트 루트: /home/geonug/kdt-linux/ML

작성 방식: 결과 CSV 재독해, 혼동행렬 재계산, Parquet hash 검증, checkpoint 메타데이터 확인, 기존 모델 CPU 재측정.

01 Executive Summary

이 프로젝트의 핵심 성과는 높은 Accuracy 자체가 아니라 평가의 신뢰도를 훼손하는 데이터 구조를 발견하고 학습·검증 설계를 수정한 과정이다. 16,232,943개 flow에서 중복과 상충 label을 확인했고, label을 포함한 초기 split을 78개 feature-only hash split으로 바꾸었다.

V3 LightGBM은 표본 validation Macro F1 0.876563에서 Test V2 0.656252로 하락했다. 분석 결과 unique-pattern deduplication과 클래스별 최대 100k cap이 Benign/Infiltration prior를 크게 왜곡한 것이 주된 설명으로 지목되었다.

V4는 frequency를 보존하고 sqrt 가중치·Benign sampling correction·Infiltration ×3 보정을 적용했다. Full Validation에서 V4-B2는 Macro F1 0.808655로 A/B1보다 개선되었다. V3 표본 validation과 V4 full validation은 모집단이 달라 점수를 직접 상승·하락률로 비교하지 않는다.

표 2. 목적별 모델 결정

모델	Accuracy	Macro F1	크기 MiB
LightGBM V4-B2	0.9793	0.8087	46.3843
DNN FP32	0.9842	0.6986	0.1286
TorchAO INT8	0.9841	0.6988	0.0459

DNN FP32는 탐지 품질보다 latency·size를 중시하는 edge 후보이다. TorchAO INT8은 FP32 품질을 실질적으로 보존했으나 현재 CPU에서 실행 비용이 증가했다. 실제 드론·ARM·NPU 성능으로 해석할 수 없다.

근거: lightgbm_top40_v4b2/metrics.csv; dnn_top40_v4/*full_valid_metrics.csv; ondevice_model_comparison.csv

02 연구 질문과 실험 Pipeline

문제와 연구 질문

① 동일 feature의 반복 및 상충 label이 일반화 평가를 왜곡하는가? ② feature 수를 줄여도 multiclass 탐지 품질을 유지할 수 있는가? ③ 빈도 손실과 클래스 prior 왜곡을 줄이면 minority 탐지가 개선되는가? ④ 경량화와 양자화는 품질·파일 크기·추론 시간·RSS에서 어떤 trade-off를 보이는가?

표 3. 연구 흐름과 의사결정

단계	실제 수행·검증 내용
품질 / Security EDA	전체 profile 및 300k 표본 분포·상관 분석
중복 / conflict 진단	78-feature 패턴 중복, 상충 label, 구조적 모호성
평가 재설계	V1 label 포함 hash → V2 feature-only hash
모델 / Feature Selection	ML 비교; Full78 → Top40 → Top20 → Top10
실패 분석	V3 Test 오탐과 학습 prior distortion 확인
V4 학습 수정	빈도 복원·sqrt weight; A / B1 / B2 validation
통계 / 경량화	MW·KW·FDR; DNN FP32; 두 INT8 방식
배포 후보 검토	CPU latency·크기·process RSS; SOC 연결 제안

선택 지표

Accuracy는 다수 Benign의 정답에 크게 좌우된다. Macro F1은 클래스별 F1을 동일 비중으로 평균하므로 드문 공격의 미탐을 더 잘 드러낸다. 따라서 모델 선택에는 Macro F1을 우선하고 class별 recall/F1·weighted F1·오탐을 함께 검토한다.

구현 근거: notebooks/preprocessing.ipynb; model_sample_v4.ipynb; statistical_analysis_v4.ipynb; scripts/benchmark_model_memory.py

03 Dataset Overview

주 데이터셋은 CSE-CIC-IDS2018이다. merged CSV 존재 및 파일 크기를 확인했으며 16M CSV 전체를 pandas로 로드하지 않았다. 다음 수치는 기존 EDA CSV를 재독해한 값이다.

표 4. 원본 profile

항목	확인값
행 / 컬럼	16,232,943 / 81
classes / Benign	15 / 83.0700%
SQL Injection	87 rows
EDA 분포 표본	300,000 rows
원본 feature_columns / 모델 입력	79 / 78 (Timestamp-metadata 등 제외)




그림 1. 그림: 실제 class_distribution.csv의 클래스별 행 수. 로그 축으로 극소수 공격을 표시.

이 데이터의 성능은 공개 보안 flow 분류 성능이다. 실제 드론 네트워크에서의 탐지율·하드웨어 처리 성능을 직접 나타내지 않는다.

근거: results/data_quality/dataset_profile.csv; class_distribution.csv; data/processed/cse_cic_ids2018/cse_cic_ids2018_merged.csv

04 Data Quality Analysis

문제

NaN/무한대, 극단 분포, 반복 행은 모델 입력 안정성과 평가 독립성에 영향을 준다. 일반적인 전체행 중복과 78-feature-only 중복은 정의가 다르므로 같은 지표로 합치지 않는다.

표 5. 기존 전체 profile에서 재확인

지표	값	해석
NaN	59,721	결측 셀 수
±Inf	131,799	비정상 수치 셀 수
generic duplicate rows	422,815	source_file 제외; Timestamp·Label 유지
duplicate ratio	2.6047%	전체행 대비 비율
pandas memory 추정	10.937 GB	EDA 기록의 추정치; 실제 로드 안 함

표 6. IQR outlier 표본 분석의 상위 항목

Feature	표본 outlier 수	비율 %
Bwd IAT Min	73,244	24.415
Bwd IAT Max	71,434	23.811
Bwd IAT Std	70,630	23.543
Fwd IAT Min	68,172	22.724
Flow IAT Max	65,327	21.776
Fwd IAT Max	60,436	20.145

해석과 다음 결정

보안 트래픽의 극단값은 공격 행동 자체일 수 있다. IQR 밖이라는 이유만으로 공격 표본을 제거하지 않는다. 분포·상관관계는 표본 분석임을 구분하고, 중복·label conflict는 모델 feature 기준으로 따로 진단한다.

근거: dataset_profile.csv; outlier_report.csv; feature_distribution.csv. 요청된 data_quality_report.csv는 저장소에 없어 profile 및 notebook 결과로 대체.

05 Security EDA: 행동 특성

시간 간격(IAT), rate, flow duration, packet length 계열이 주요 후보로 나타났다. 아래는 기존 후보 CSV의 Benign/Attack 중앙값이며, 단위가 다른 feature의 원시 차이를 직접 중요도로 해석하지 않는다.

표 7. Security EDA 후보의 중앙값

Feature	Benign median	Attack median
Fwd IAT Min	29.000	329.000
Fwd Pkts/s	39.781	204.506
Flow Pkts/s	81.756	281.571
Fwd Pkt Len Max	44.000	0.000
TotLen Fwd Pkts	51.000	0.000
Flow Byts/s	1076.681	0.000
Bwd Pkt Len Max	104.000	0.000
Bwd Pkt Len Mean	79.000	0.000
Fwd Pkt Len Mean	40.000	0.000




그림 2. 그림: 기존 클래스별 Flow IAT Mean 분석 이미지.

Attack 전체를 하나로 묶은 평균·중앙값은 DoS, brute-force, infiltration 등 공격의 이질성을 가릴 수 있다. 클래스별 분포와 TCP flag·packet length를 함께 읽어야 하며 단일 임계값만으로 15-class 분류를 설명하기 어렵다.

근거: network_eda/eda_feature_candidates.csv; key_feature_median_by_attack.csv; benign_attack_mean.csv; tcp_flag_mean_by_label.csv

06 고상관 Feature와 중복 정보

표 8. 고상관 pair: 기존 표본의 Pearson correlation

Feature A	Feature B	r
RST Flag Cnt	ECE Flag Cnt	0.999988
Flow Duration	Fwd IAT Tot	0.996835
Idle Mean	Idle Min	0.996692
Idle Mean	Idle Max	0.995985
Tot Bwd Pkts	TotLen Bwd Pkts	0.995241
Pkt Len Mean	Pkt Size Avg	0.992742
Flow IAT Max	Fwd IAT Max	0.992535
Flow IAT Mean	Flow IAT Min	0.992176
Flow IAT Mean	Fwd IAT Mean	0.990776
Flow IAT Mean	Fwd IAT Min	0.989138
Fwd IAT Mean	Fwd IAT Min	0.987250

RST/ECE, Flow Duration/Fwd IAT Tot, packet length 평균 계열에는 거의 중복되는 정보가 있다. 이 결과는 feature 축소의 출발점이지만 높은 상관만으로 자동 제거하지 않았다. 트리 중요도·실제 축소 성능·conflict projection·통계 검증을 함께 사용했다.

높은 상관은 인과관계를 뜻하지 않는다. 표본 구성·정의상 연결·극단값의 영향이 포함될 수 있으며 실제 배포 분포에서 다시 확인할 필요가 있다.

근거: results/network_eda/high_correlation_candidates.csv; eda_feature_correlation_pairs.csv; results/data_quality/feature_correlation_pairs.csv

07 Duplicate: 행 수와 정보량의 차이

반복 flow가 많으면 행 수가 커도 독립적인 패턴 정보는 작다. random split에서는 같은 패턴이 학습과 평가에 반복되어 기억 기반의 점수가 높아질 수 있다. 특히 brute-force와 SlowHTTP 계열에서 반복이 집중되었다.

표 9. Train V2의 78-feature 패턴별 통계

Class	Rows	Unique	Rows / pattern
Benign	9,451,891	7,445,818	1.27
DoS attacks-SlowHTTPTest	85,458	44	1942.23
FTP-BruteForce	173,083	39	4438.03
Infiltration	113,111	98,237	1.15
SSH-Bruteforce	155,484	66,117	2.35

설계상의 의미

SlowHTTPTest는 85,458행이 44패턴, FTP-BruteForce는 173,083행이 39패턴에 집중됐다. SSH도 155,484행 대비 66,117 패턴으로 중복이 상당하다. 이를 동일 feature 패턴 단위로 split하되, 학습에서 원래 빈도까지 지워버리면 prior가 변할 수 있다.

따라서 split의 독립성을 확보하는 것과 학습 빈도를 보존하는 것은 별개의 목표다. V2는 평가 누수를 줄이고, V4는 deduplication 이후 frequency 정보를 가중치로 다시 반영한다.

표 10. 빈도 checkpoint 검증

검증	결과
클래스별 SUM(frequency) = original_rows	True
복원 행 수 합계	11,416,137
빈도 CSV classes	15

근거: split_diagnosis/split_v2_train_pattern_stats.csv; model_sample_v4/frequency_checkpoint_integrity.csv

08 Label Conflict와 Structural Ambiguity

동일한 78-feature vector에 서로 다른 label이 있는 경우 현재 관측 입력만으로 정답을 완전히 구분하기 어렵다. 이 데이터를 점수 개선을 위해 임의로 삭제하지 않고 모호성을 보존했다.

표 11. 전체 Split V2 재검증: 64-bit feature hash 기준

항목	재확인값
Conflicting patterns	22,373
Affected rows	423,390
최대 labels / pattern	3

표 12. Label pair별 conflict

Class pair	Patterns	Affected pair rows
9 ↔ 11	12	239,731
0 ↔ 12	22348	170,849
11 ↔ 14	7	169,775
9 ↔ 14	5	68,697
2 ↔ 13	5	24
0 ↔ 2	3	11
0 ↔ 13	1	4
0 ↔ 3	1	2
3 ↔ 13	1	2

표의 label ID는 0 Benign, 2 Web, 9 SlowHTTPTest, 11 FTP, 12 Infiltration, 13 SQL, 14 SSH이다. Pair affected rows는 해당 두 label의 빈도 합이며 3-label 패턴은 여러 pair에 포함된다. 따라서 pair 합을 전체 affected rows와 동일시하면 안 된다.

재검증은 bounded-memory DuckDB로 78-feature hash를 집계했다. hash 일치는 구조적 중복의 실용적 확인이며 충돌 가능성을 수학적으로 배제하지 않는다. 실제 값의 NULL-safe join으로 확인한 V4 주요 pair 결과도 후속 분석에 사용했다.

근거: README.md의 기존 전체 conflict 기록; final_report/data_verification.json; label_conflict_pairs_verified.csv; model_sample_v4.ipynb의 pair join

09 Split V1 문제와 V2 재설계

문제 → 원인

V1은 hash(features + label_id)를 사용했다. 같은 feature라도 label이 다르면 hash가 달라져 다른 split으로 갈 수 있다. features+label 조합 overlap 0만으로 feature-level 누수 방지를 입증할 수 없는 이유다.

실험 설계

V2는 metadata·label을 제외한 모델 입력 78개 feature의 hash bucket을 사용한다. bucket <70은 Train, 70-84는 Validation, ≥85는 Test로 배정하여 feature pattern 전체가 한 split에만 존재하도록 한다.

표 13. Parquet footer 및 hash 재검증

항목	검증값
Train rows	11,416,137
Validation rows	2,390,002
Test rows	2,426,804
Train-Validation hash overlap	0
Train-Test hash overlap	0
Validation-Test hash overlap	0

이는 반복 패턴이 split 간 분산될 수 있는 일반 random split보다 패턴 일반화에 엄격하다. 다만 시간·호스트·수집일 기준의 독립성을 보장하지 않는다. 빈도가 큰 패턴이 한 split에 집중되므로 클래스별 비율이 70/15/15에 정확히 맞지는 않는다.

기존 notebook의 overlap 출력 중 V1 경로 결과와 V2 근거를 혼동하지 않았다. 본 보고서는 실제 V2 Parquet에서 hash overlap을 다시 계산했다. Test label 집계는 결과 감사이며 V4 선택이나 튜닝에는 사용하지 않았다.

근거: notebooks/preprocessing.ipynb; network_ml_split_v2/*.parquet; final_report/verify_data.py; data_verification.json

10 V3 Baseline Model Comparison

표 14. 동일 V3 표본 validation의 모델 비교

모델 / feature	Accuracy	Macro F1
LightGBM-Top40	0.945792	0.876563
XGBoost-Top40	0.943117	0.859573
XGBoost-Full78	0.945546	0.846377
HistGradientBoosting-Top40	0.941294	0.844567
MLP-Top40	0.923495	0.827712
RandomForest-Top40	0.942991	0.825171
LogisticRegression-Top40	0.831273	0.588358




그림 3. 그림: 기존 V3 모델 비교 이미지. 전체 Validation 성능과 구분한다.




그림 4. 그림: 기존 V3 Accuracy와 Macro F1 비교.

LightGBM Top40이 이 development 표본에서 가장 높은 Macro F1을 보였다. V3 validation support는 142,082개이며, 클래스당 최대 20k 등 샘플링이 적용된 데이터다. 이 점수는 자연 분포의 대규모 holdout 성능과 같지 않다.

근거: results/model_comparison_v3/model_diversity_comparison.csv; 각 모델 validation_metrics.csv; xgboost_v3/validation_metrics.csv

11 Feature Importance / Reduction

표 15. XGBoost feature 축소 실험

Set	입력 수	Macro F1	감소 %
Full78	78	0.846377	0.000000
Top40	40	0.859573	48.717949
Top20	20	0.849831	74.358974
Top10	10	0.808544	87.179487




그림 5. 그림: 실제 Full78 importance CSV의 상위 split gain.




그림 6. 그림: 실제 feature 축소 CSV 재시각화.

Top40은 78→40으로 입력 수를 48.7179% 줄이면서 Macro F1을 0.846377→0.859573으로 높였다. Top10에서는 0.808544로 하락해 과도한 축소의 손실이 관찰됐다. Top40을 이후 기본 feature set으로 선택했다.

근거: feature_selection/feature_reduction_comparison_v3.csv; top40_features.csv; xgboost_v3/feature_importance_full78.csv

12 V3 클래스별 진단과 기존 결과




그림 7. 그림: 기존 Feature Reduction 실험 결과.




그림 8. 그림: V3 표본 validation 클래스별 F1.




그림 9. 그림: V3 표본 validation 혼동행렬. 최종 Test 혼동행렬이 아니다.

전체 평균만으로 minority 오탐·미탐을 설명하기 어렵다. 그림의 평가 범위를 V3 표본 validation으로 고정하고, 이후 실제 Test에서 발생한 대규모 Benign 오탐을 별도로 분석한다.

근거: results/experiment_report/figures/03-05; lightgbm_top40_v3/classification_report.csv 및 confusion_matrix.csv

13 Ensemble / 오류 패턴 분석




그림 10. 그림: 기존 XGBoost-LightGBM 정오답 agreement 분석.




그림 11. 그림: 기존 Benign/Infiltration 오류 분석.

서로 다른 트리 모델의 오류가 상당 부분 겹친다면 단순 ensemble만으로 해결 가능한 여지가 제한된다. 실제 ensemble weight CSV에서는 LightGBM 단독 Macro F1 0.876563보다 50:50 혼합 0.864666이 낮았다. Accuracy가 약간 상승해도 모델 선택 목적과 일치하지 않는다.

반복되는 Benign/Infiltration 오류는 이후 class prior와 feature ambiguity 분석으로 연결했다. 모델 구조를 바꾸기 전에 데이터 분포와 평가 단위를 확인한 것이 핵심 의사결정이다.

근거: ensemble_analysis_v3/xgb_lgbm_agreement.csv; xgb_lgbm_disagreement_by_class.csv;
xgb_lgbm_ensemble_v3/ensemble_weight_comparison.csv

14 V3 Final Test 실패 분석

표 16. Test V2: 저장된 혼동행렬에서 재계산

Metric	Value
accuracy	0.689660
macro_precision	0.647634
macro_recall	0.787883
macro_f1	0.656252
weighted_f1	0.795021

표 17. 대표 오류: true → predicted

오류 방향	건수
Benign → Infiltration	699,881
SlowHTTPTest → FTP	47,535
Infiltration → Benign	3,388
FTP → SlowHTTPTest	1,272

전체 Test 2,426,804개에서 Benign 오탐이 매우 컸다. 원인은 unique pattern 자체보다 deduplication + per-class 최대 100k cap sampling이 원래 빈도 및 클래스 비율을 왜곡한 데 있다는 분석이다.

표 18. Benign : Infiltration 학습 prior

모집단	비율
Original Train V2	83.56 : 1
V3 capped sample	1.02 : 1

관측 오류와 prior 왜곡은 일관된 설명이지만 단일 요인만 분리한 인과 ablation은 없다. V4에서는 frequency-aware 학습을 설계해 이 가설을 validation에서 검증했다. Test V2는 이 시점에 소비되었으므로 V4 선택·추가 튜닝에는 재사용하지 않았다.

근거: final_evaluation/test_confusion_matrix.csv; model_sample_v4/v2_v3_distribution_compare.csv; notebooks/final_evaluation.ipynb

15 V4 Frequency-Aware 학습 재설계

문제와 실험 설계

중복을 제거해 독립 패턴을 확보하되 각 패턴이 원래 몇 번 관측됐는지 frequency를 저장했다. 클래스별 SUM(frequency)가 Train V2 원래 행 수와 일치하는지 checkpoint integrity CSV로 검증했다.

표 19. Weight 후보와 최초 선택 근거

전략	특성 / 판단
unique (=1)	모든 패턴 동일; 빈도 정보를 잃음
$\log_{10}(\text{frequency})$	강한 압축; 고빈도 신호를 약하게 반영
$\sqrt{\text{frequency}}$	빈도를 반영하되 반복 패턴 지배를 완화
raw frequency	원래 행 빈도 재현; 극단 반복 영향이 큼

$\sqrt{\text{frequency}}$ 는 frequency 보존과 고빈도 과지배 사이의 절충으로 첫 전략에 사용했다. 모든 후보를 동일 조건에서 최적화한 결과라고 주장하지 않는다. $\sqrt{\text{frequency}}$ 가중치는 원래 prior를 정확히 복원하는 raw frequency와도 다르다.

표 20. V4-A 학습 구성

항목	값 / 구현
Benign	Top40 unique reservoir sample 1,000,000
기타 class	unique patterns 전체 사용
sample weight	$\sqrt{\text{frequency}}$
Benign correction	전체 unique / sample = 7.445262
학습 pattern 합계	1,946,494

Top40 projection 후 같은 패턴으로 합쳐지는 경우 frequency 합을 보존했다. Benign 표본에는 sampling correction을 곱해 표본 축소가 유효 weight를 다시 왜곡하는 것을 줄였다.

근거: notebooks/model_sample_v4.ipynb cells 46-50; frequency_checkpoint_integrity.csv; top40_projection_integrity.csv; network_ml_dev_v4/training/*.parquet

16 V4-A / B1 / B2 선택

표 21. 동일 Full Validation: 2,390,002 rows

모델	Accuracy	Macro F1	Weighted F1
LightGBM Top40 V4-A	0.980710	0.792164	0.976229
LightGBM Top40 V4-B1	0.979876	0.802962	0.976984
LightGBM Top40 V4-B2	0.979313	0.808655	0.977194

V3 → V4: 평가 모집단을 구분한 Macro F1




그림 12. 그림: V3/V4 실험 흐름. V3 dev-Test-V4 validation의 모집단이 달라 연결된 인과 성능 추세로 해석하지 않는다.

표 22. Infiltration (label 12) 개선

단계	Recall	F1
A ×1	0.109207	0.171618
B1 ×2	0.227714	0.286276
B2 ×3	0.272063	0.310527

V4-B2는 Accuracy를 소폭 희생하며 Macro F1-Infiltration recall/F1을 개선해 최종 development model로 선택됐다. B2의 precision/recall/F1은 0.833441/0.830082/0.808655다. ×4, ×5의 연속 탐색은 수행하지 않았으며 validation에 대한 반복 선택 편향을 늘리지 않는 제한된 탐색으로 해석한다.

근거: lightgbm_top40_v4*/metrics.csv; v4_model_comparison/focus_class_metrics.csv. V4 independent Test 결과가 아니다.

17 Structural Ambiguity의 한계

Validation의 동일 Top40 패턴이 다른 label을 갖는 경우, 패턴마다 작은 쪽 빈도를 합하면 deterministic feature-only 분류기의 피할 수 없는 pair 오류 하한을 얻는다. 아래 ambiguity 비율의 분모는 전체 class rows가 아니라 pair conflict rows이다.

표 23. 실제 notebook Validation pair 결과

Pair	A conflict %	B conflict %	Ambiguity %
SlowHTTP / FTP	79.1340	28.6714	40.9179
Benign / Infiltration	0.9502	25.6346	24.1734

표 24. 분자·분모 확인

Pair	Conflicting rows	Minority sum
SlowHTTP / FTP	5,446 + 5,449 = 10,895	4,458
Benign / Infiltration	19,125 + 6,312 = 25,437	6,149

이는 전체 모델 Macro F1의 직접적인 ceiling 수치가 아니다. SlowHTTP/FTP에서 특히 구조적 모호성이 강하며 일반 hyperparameter tuning만으로 동일 입력의 서로 다른 정답을 모두 맞힐 수 없다. 새 feature·추가 문맥·label 검토가 필요하다.

Benign/Infiltration은 대부분 비충돌 패턴이므로 weighting으로 개선할 여지가 있었다. 실제 V4-B2에서 minority recall이 개선됐다. 반면 FTP는 B2에서도 F1 0.040371로 낮아 해결된 문제로 표현하지 않는다.

표 25. Train의 feature projection 영향

Pair	Set	Patterns	Ambiguity
SlowHTTP / FTP	Full78	10	0.2912
SlowHTTP / FTP	Top40	10	0.2912
Benign / Infiltration	Full78	15,493	0.2366
Benign / Infiltration	Top40	15,508	0.2366

근거: model_sample_v4.ipynb cells 64-65; full78_vs_top40_conflict.csv; v4b2/per_class_metrics.csv

18 통계 검증: Mann-Whitney U

기존 분석은 Benign 100k와 Attack 100k로 기록됐지만, 저장 Parquet의 label을 다시 확인한 결과 Attack 표본은 Bot(label 1) 100k만 포함했다. 실제 해석 범위는 Benign vs Bot의 비모수 분포 검증이다. feature마다 finite 값만 사용하고 Benjamini-Hochberg FDR 보정을 적용했다. p-value와 함께 rank-biserial effect size를 보아 표본 크기로 인한 작은 차이의 유의성을 구분했다.

표 26. Binary 검증 요약

검증 항목	CSV 결과
FDR significant	38 / 40
PSH Flag Cnt	FDR p = 0.488020; effect = 0.001550
Fwd URG Flags	상수값; p-value NaN / 효과 0
signed effect	$2U/(n_{\text{Benign}} \times n_{\text{Attack}}) - 1$




그림 13. 그림: 주요 signed effect. 음수는 Benign 값이 Bot보다 작은 방향; 크기는 분포 분리 정도를 나타낸다.

표 27. 주요 feature 실제 effect

Feature	Effect
Dst Port	-0.732210
Fwd Pkts/s	-0.551948
Flow Duration	0.499302
Flow IAT Mean	0.492709
Pkt Size Avg	0.490014

38/40은 비유의 1개와 상수값 1개를 제외한 집계다. 코드의 WHERE label_id != 0 LIMIT 100000은 순서에 따라 Bot만 선택했다. 따라서 모든 Attack의 분리 효과로 일반화할 수 없다. feature 상관·중복도 검증 독립성에 영향을 준다.

근거: statistical_analysis_v4/mann_whitney_top40.csv; notebooks/statistical_analysis_v4.ipynb

19 통계 검증: 15-class Kruskal-Wallis

15개 class의 분포 차이를 비교했다. 클래스별 최대 20k인 Train 표본이며 총 209,618 rows를 사용했다. 이 표본도 클래스별 LIMIT 기반이므로 무작위 대표 표본이라고 할 수 없다. 극소수 SQL 등은 원래 확보 가능한 support를 사용했다. FDR 보정 후 40/40 feature가 유의하고 38개가 large effect로 분류됐다.




그림 14. 그림: 15-class 분포 분리를 나타내는 epsilon-squared 상위 feature.

표 28. 검정 맥락 차이

Feature	MW binary	KW multiclass
PSH Flag Cnt	비유의 $p=0.488020$	$\epsilon^2=0.211613$ / large
Fwd URG Flags	상수 / 검정 불가	$\epsilon^2=0.010348$

Binary p-value만으로 PSH Flag Cnt를 제거하면 multiclass 정보를 잃을 수 있다. 특히 실제 MW는 Benign vs Bot 비교이므로 그 비유의 결과를 다른 13개 공격으로 일반화할 수 없다. KW는 15-class 차이를 평가한다.

Top40은 통계 검정으로만 선별한 목록이 아니다. 모델 importance, 축소 성능 실험, Full78→Top40 conflict projection, 사후 통계 검증을 종합해 타당성을 확인한 feature set이다. 검정은 Train에서 수행했으며 V4 최종 holdout 검증을 대신하지 않는다.

근거: kruskal_wallis_top40.csv; top40_statistical_validation.csv; feature_selection/top40_features.csv; model_sample_v4/full78_vs_top40_conflict.csv

20 DNN Lightweight Model

표 29. 구조 / artifact 검증

항목	확인 내용
입력 / 출력	40 features / 15 classes
구조	Linear128 → BN → ReLU → Dropout0.2
중간층	Linear128 → BN → ReLU → Dropout0.2
마지막층	Linear64 → ReLU → Linear15
Best epoch	13 / checkpoint 및 history 일치
Dev subset Macro F1	0.663038
Train scaler	40 features; n_samples_seen = 1,946,494

표 30. FP32 Full Validation

Metric	Value
accuracy	0.984179
macro_precision	0.717727
macro_recall	0.704297
macro_f1	0.698647
weighted_f1	0.981440




그림 15. 그림: Accuracy 순위와 Macro F1 순위가 달라지는 실제 사례.

DNN은 Accuracy 0.984179로 LightGBM보다 높지만 Macro F1 0.698647로 낮다. 더 좋은 탐지 모델이라고 표현하지 않고 경량 On-Device 후보로 평가한다.

StandardScaler의 Train-only fit 및 V4-B2 sample_weight를 사용한 weighted Cross Entropy는 제공된 실험 설계다. 저장된 scaler sample 수와 checkpoint는 설계와 일치하나 학습 notebook이 0-byte여서 fit 대상·loss 구현 코드는 독립적으로 완전히 감사할 수 없었다.

근거: models/network/dnn_top40_v4_best.pt; dnn_top40_v4_scaler.joblib; training_history.csv; scripts/benchmark_model_memory.py; dnn_fp32_full_valid_metrics.csv

21 INT8 Quantization: 성공과 실패 기록

표 31. 두 방식의 실험 기록

실험	Accuracy	Macro F1	근거 상태
Legacy Dynamic INT8	0.878532	0.286261	제공값 / 원본 결과 부재
DNN FP32	0.984179	0.698647	실제 Full Valid CSV
TorchAO INT8	0.984110	0.698836	실제 Full Valid CSV

Legacy torch.ao.quantization.quantize_dynamic checkpoint는 존재하며 quantization=dynamic_int8_linear, source_epoch=13을 확인했다. 성능 붕괴로 rejected였다는 제공된 기록은 보존한다. Weighted F1 0.865403과 FP32 agreement 0.885160은 원본 metric 파일이 없어 검증된 측정치로 승격하지 않았다.

TorchAO 재측정 코드는 Int8DynamicActivationInt8WeightConfig를 사용한다. 제공된 8192-row sanity agreement 0.999878 및 changed 1/8192는 원본 출력 부재로 미확인 참고 기록이다. Full Validation 품질은 실제 CSV로 확인됐다.

표 32. TorchAO FP32: 같은 Full Validation

accuracy	-0.000068
macro_precision	+0.000907
macro_recall	-0.000699
macro_f1	+0.000189
weighted_f1	-0.000031

동일 Full Validation: 탐지 품질 비교




그림 16. 그림: 동일 2,390,002-row Validation의 Macro F1.

Macro F1 +0.000189는 양자화의 탐지 성능 향상으로 과장할 수 없다. 측정된 작은 차이는 실질적인 FP32 품질 보존으로 해석하며 통계적 개선을 주장하지 않는다.

근거: dnn_*full_valid_metrics.csv; dynamic_int8.pt metadata; scripts/benchmark_model_memory.py. Legacy 및 sanity의 원본 결과 부재를 명시.

22 CPU Benchmark 환경과 파일 크기

요청된 results/ondevice_benchmark_v4/inference_benchmark.csv는 존재하지 않고 해당 notebook은 0-byte다. 따라서 제공된 latency-RSS를 실제 파일 측정치로 인용하지 않았다. 본 보고서는 기존 모델을 재학습 없이 별도 fresh process에서 순차 재측정했다.

표 33. 재측정 조건

항목	조건
OS / CPU	WSL2 Linux x86_64 / Intel Core i5-12400
PyTorch	2.14.1+cu130
Thread	CPU 1-thread / interop 1
Input	동일 Top40, Validation 첫 4096 rows
전처리	LGBM raw+NaN; DNN Train scaler 적용
Timing	전처리·disk I/O 제외; warmup 2
반복	LGBM 3회 / DNN 30회; median
측정 범위	forward/predict; 모델 load 제외

추론 가중치 / 모델 파일 크기




그림 17. 그림: 실제 serialized file 크기. MiB = bytes/1024²; 로그 축.

DNN FP32는 순수 state_dict 파일 0.1286 MiB이고 best checkpoint는 optimizer 등으로 더 크다. 표의 비교는 추론 artifact 다. scaler·입력 schema·Python runtime·설치 패키지는 이 파일 크기에 포함되지 않는다.

근거: benchmark_environment.json; verify_benchmark.py; 모델 파일 stat. 실제 ARM/NPU/드론 보드 benchmark가 아니다.

23 Batch size별 Inference Latency




그림 18. 그림: 재측정 median latency (ms/batch); y-axis log scale.

표 34. 재측정 순수 inference latency (ms)

모델	batch1	batch32	batch256	batch4096
LightGBM V4-B2	3.8083	98.7821	669.4601	11414.4773
DNN FP32	0.0343	0.0599	0.2990	5.6104
TorchAO INT8	0.6289	1.3803	4.6805	77.3871

DNN FP32는 작은 batch에서 가장 낮은 latency를 보였고, INT8은 작은 파일에도 activation 양자화-kernel/runtime 경로로 인해 overhead가 컸다. LightGBM은 높은 Macro F1과 더 큰 추론 비용 사이의 trade-off를 보였다.

원래 제공된 FP32 batch1 0.0374ms·batch4096 3.2689ms, INT8 0.5198ms·63.5359ms, LightGBM 4.2867ms·7140.9082ms는 provenance가 확인되지 않은 참고값이다. 재측정 값과 차이는 별도 CSV에 보존했으며 환경·반복·입력 처리 조건이 달라 동일 실험의 재현 오차로 단정하지 않는다.

LGBM의 반복 횟수는 비용 때문에 3회로 제한해 CPU 변동에 취약하다. p99·실시간 deadline·동시 처리·전처리 포함 end-to-end 성능은 측정하지 않았다.

근거: inference_benchmark_verified.csv; provided_reference_values.csv; verify_benchmark.py

24 Batch Throughput와 Edge 해석




그림 19. 그림: batch/median_seconds로 계산한 처리량. 로그 축.

표 35. Batch4096 throughput

모델	실제 재측정 flows/s	제공 참고 flows/s
LightGBM V4-B2	359	574
DNN FP32	730,078	1,253,030
TorchAO INT8	52,929	64,468

throughput은 같은 latency에서 계산한 batch 처리량이며 독립적인 측정 지표가 아니다. batch를 채우는 대기·flow 추출·feature 전처리·전송·SOC 처리 시간은 제외됐다. batch4096 수치를 단일 flow 실시간 응답 속도로 해석할 수 없다.

edge 후보는 우선 DNN FP32다. 낮은 파일 크기·CPU latency는 장점이지만 minority-class 탐지 품질 저하는 운영 위험이다. 탐지 threshold·후속 서버 재평가·추가 문맥을 설계하고 실제 target board에서 확인해야 한다.

INT8은 저장 공간 최소화 후보로 남긴다. 현재 x86 CPU 결과만으로 ARM/NPU에서 빠를 것이라고 단정할 수 없으며, backend·kernel 지원과 실제 입력 분포를 포함한 target 검증이 필요하다.

근거: final_report/ondevice_model_comparison.csv; inference_benchmark_verified.csv. CSE-CIC-IDS2018 처리량이며 실제 드론 성능 아님.

25 Runtime Memory Benchmark

표 36. Fresh Python process의 재측정 RSS (MiB)

Stage	LightGBM	FP32	INT8
baseline_rss_mb	645.3672	645.4570	645.4414
after_input_rss_mb	683.7344	728.0430	728.0039
after_model_rss_mb	722.4219	732.0938	891.0391
after_inference_rss_mb	723.0039	738.0938	896.7070
peak_rss_mb	777.6836	741.5859	902.7344
model_load_delta_mb	38.6875	4.0508	163.0352
peak_delta_from_baseline_mb	132.3164	96.1289	257.2930

모델 로드 전후 process RSS 순변화




그림 20. 그림: after_model - after_input process RSS. 음수도 순변화로 그대로 표시.

프로세스 baseline 대비 peak RSS 증가




그림 21. 그림: lifetime peak RSS - baseline. 모델 weight memory가 아니다.

RSS는 Python·PyTorch·TorchAO·LightGBM 및 입력·kernel 초기화·allocator 동작을 포함한다. net model-load delta는 할당과 해제가 함께 반영되어 음수가 될 수도 있으며 음수 weight memory를 뜻하지 않는다. INT8 load는 FP32 로드 후 runtime 양자화 비용도 포함한다.

근거: memory_*.json; runtime_memory_verified.csv; verify_benchmark.py. 원래 제공된 RSS와 달라 본 재측정을 별도 결과로 기록.

26 최종 모델 Trade-off

표 37. 목적별 후보와 의사결정

목적	후보	결정 근거 / 남은 과제
Detection Quality	LightGBM V4-B2	Macro F1 0.808655; 서버/SOC 분석 후보
On-Device / Edge	DNN FP32	0.1286 MiB; 낮은 CPU latency; minority 약점
Extreme Storage	TorchAO INT8	0.0459 MiB; FP32 품질 보존; CPU overhead

동일 Full Validation: 탐지 품질 비교




그림 22. 그림: 운영 목적이 달라 단일 winner를 강제하지 않는다.

LightGBM은 동일 Full Validation의 Macro F1 최고 모델이지만 실제 운영 탐지율을 보증하지 않는다. DNN FP32는 저장 공간·추론 시간에서 유리하나 LightGBM보다 탐지 품질이 낮다. INT8은 더 작은 파일을 얻었지만 이 CPU에서는 latency·RSS 비용이 증가했다.

따라서 서버측 품질 중심 후보와 edge 계산 제약 후보를 구분한다. V4 모델은 development 선택 결과이며 신규 independent holdout과 실제 트래픽·하드웨어 평가 이후 배포 결정을 내려야 한다.

근거: ondevice_model_comparison.csv; V4 metrics CSV; runtime_memory_verified.csv

27 Autonomous SOC Agent 통합 전략

이 저장소는 네트워크 AI 실험 산출물을 제공한다. Security AI Adapter:ThreatAssessor 연결이 이 저장소에서 완료되었다는 근거는 없으므로 다음 내용은 향후 통합 설계 제안이다.

표 38. 제안하는 처리 흐름

단계	역할
Network Flow	동일 40-feature 추출 / schema·단위 검증
Security AI Adapter	모델·전처리 버전·feature 순서·결측 정책 고정
LGBM / DNN inference	서버 품질 모델 또는 edge 추론 후보
Normalized threat evidence	class score·model version·flow 문맥·불확실성
ThreatAssessor	추론 evidence와 다른 보안 신호를 결합
Investigation	추가 로그·네트워크 문맥·오답 확인
Policy / Human Approval	신뢰도·정책에 따른 검토·승인
Response	승인된 대응 실행 및 감사 기록

모델별 배치 후보

LightGBM은 서버/SOC에서 탐지 품질을 우선하는 분석 후보다. DNN FP32는 edge에서 저비용 evidence를 생성하는 후보이며 필요 시 서버측 재평가와 연결할 수 있다. INT8은 target device 평가가 선행돼야 한다.

클래스 score를 보정된 공격 확률로 바로 해석하지 않는다. class ambiguity·drift·feature extraction 실패를 evidence에 포함하고, 불확실한 결과가 자동 차단으로 곧바로 이어지지 않도록 정책과 검토 절차를 설계한다.

통합 구현 상태: 제안 / 미구현. 저장소 src/ml 및 README를 확인했으며 완료된 adapter 코드는 확인되지 않음.

28 Limitations / Conclusion

표 39. 검증의 범위와 남은 과제

제약	영향 / 다음 검증
데이터 duplicate / label ambiguity	같은 flow feature에 상충 label; 추가 문맥·label 검토 필요
작은 minority support	SQL 전체 87개; split별 추정 불안정
V4 validation 중심 개발	선택 편향 가능; 신규 independent final holdout 필요
Test V2 소비	V3 평가·실패 분석에서 사용; V4 선택에 재사용하지 않음
DNN minority 성능	높은 Accuracy에도 Macro F1 낮음
SlowHTTP / FTP ambiguity	튜닝만으로 해결 어려움; FTP F1 여전히 낮음
WSL/x86 benchmark	실제 embedded board·ARM·NPU·드론 성능 아님
INT8 target 의존성	backend·kernel·target hardware별 검증 필요
드론 traffic 일반화	실제 drone network traffic에서 검증 안 됨
통계 표본 대표성	MW Attack 100k는 Bot만 포함; KW도 LIMIT 표본
Artifact 공백	빈 DNN/benchmark notebook; 일부 원본 결과 없음

결론

이 프로젝트는 점수만 보고 모델을 선택하는 과정을 넘어 데이터의 품질·평가 독립성·학습 prior를 진단하고 설계를 재구성했다. V3 실패를 숨기지 않고 V4 frequency-aware 학습으로 연결했으며 통계 검증·양자화·CPU benchmark로 모델별 trade-off를 확인했다.

Detection Quality에는 LightGBM V4-B2, Edge에는 DNN FP32, 저장 공간 최소화 실험에는 TorchAO INT8을 후보로 제시한다. 통합과 실제 target 검증은 남은 작업으로 명시한다.

모든 확정 성능 수치는 기존 결과 CSV 또는 본 보고서에서 실행한 검증 파일에 근거한다. 제공값과 원본 파일이 없는 항목은 참고 기록으로 구분했다.

29 근거 감사와 재현 가능성

표 40. 사용자 제공값과 실제 파일 대조

항목	감사 결과
Dataset / V3 / V4 metrics	CSV와 일치 (반올림 오차 범위)
V3 Test metrics / 오류	저장 혼동행렬에서 재계산 일치
Split V2 / conflict	Parquet footer 및 feature hash 재검증
DNN epoch / model size	Checkpoint·history·file stat으로 확인
MW 실제 sample label	Attack 100k는 Bot만 포함; 전체 Attack 검정 아님
Legacy INT8 / 8192 sanity	Checkpoint 존재; 해당 수치 원본 출력 부재
Original latency / RSS	결과 CSV 부재; 제공값을 별도 참고 CSV에 보존
본 보고서 latency / RSS	기존 모델로 재측정; 조건·값은 별도 결과
학습 코드 감사 한계	DNN/benchmark notebook 0-byte; loss·fit 코드 불충분

표 41. 과거 RSS 제공 기록: 원본 결과 부재 / 미확인 (MiB)

Stage	LightGBM	FP32	INT8
baseline_rss_mb	644.4727	642.7344	645.2188
after_input_rss_mb	705.7148	679.6484	679.3594
after_model_rss_mb	730.8711	683.1719	808.5977
after_inference_rss_mb	692.2109	687.0430	792.9258
peak_rss_mb	786.8594	690.4648	820.3633
model_load_delta_mb	25.1563	3.5234	129.2383
peak_delta_from_baseline_mb	142.3867	47.7305	175.1445

근거 전체 목록·SHA256은 source_manifest.csv에 기록했다. 추가 생성 파일은 reports/ 및 results/final_report/에만 저장했다. 기존 결과를 덮어쓰거나 모델을 재학습하지 않았다. 원본 16M CSV를 전체 로드하지 않고 DuckDB 1GB 제한과 Parquet streaming을 사용했다.

재현: .venv/bin/python results/final_report/render_final_report.py

입력 manifest: results/final_report/source_manifest.csv

공유 편집 원본: reports/CSE_CIC_IDS2018_Security_AI_Final_Experiment_Report.content.json